

Математическое обоснование метода главных компонент (РСА)

13 июня 2026 г.

1. Постановка задачи

Пусть задана центрированная матрица данных $X \in \mathbb{R}^{n \times d}$, где n — число объектов (наблюдений), а d — число исходных признаков. Выборочная матрица ковариаций имеет вид:

$$\Sigma = \frac{1}{n} X^T X \quad (1)$$

Матрица Σ является симметричной ($\Sigma^T = \Sigma$) и полуположительно определенной ($\forall v \in \mathbb{R}^d : v^T \Sigma v \geq 0$).

Мы ищем такое единичное направление (вектор $v \in \mathbb{R}^d$, удовлетворяющий условию $\|v\| = 1$), проекция данных на которое обладает максимальной дисперсией.

2. Выражение дисперсии через свойства ковариационной матрицы

Проекция выборки X на вектор v представляет собой вектор $Xv \in \mathbb{R}^n$. Используя свойства дисперсии (дисперсия линейной комбинации), найдем дисперсию спроецированных данных, учитывая, что данные централизованы:

$$\text{Var}(Xv) = \frac{1}{n} (Xv)^T (Xv) = \frac{1}{n} v^T X^T X v = v^T \left(\frac{1}{n} X^T X \right) v = v^T \Sigma v \quad (2)$$

Таким образом, формальная задача оптимизации заключается в максимизации квадратичной формы при ограничении на норму вектора:

$$\max_v v^T \Sigma v \quad \text{при условии} \quad v^T v = 1 \quad (3)$$

3. Переход к отношению Рэля (без ограничений)

Поскольку вектор v нормирован ($v^T v = 1$), задачу условной максимизации можно эквивалентно переписать в виде максимизации отношения Рэля для произвольного ненулевого вектора $y \in \mathbb{R}^d \setminus \{0\}$:

$$R(\Sigma, y) = \frac{y^T \Sigma y}{y^T y} \quad (4)$$

Любой ненулевой вектор y можно отнормировать: $v = \frac{y}{\|y\|}$, при этом значение отношения Рэлея не изменится ($R(\Sigma, y) = R(\Sigma, v) = v^T \Sigma v$). Следовательно, максимум $v^T \Sigma v$ при $\|v\| = 1$ в точности равен максимуму $R(\Sigma, y)$.

4. Доказательство через спектральную теорему

Поскольку матрица ковариаций Σ симметрична, согласно спектральной теореме линейной алгебры, её можно представить в виде ортогональной диагонализации:

$$\Sigma = Q \Lambda Q^T \quad (5)$$

Где:

- $Q = [e_1, e_2, \dots, e_d]$ — ортогональная матрица ($Q^T Q = I$), столбцы которой образуют ортонормированный базис из собственных векторов матрицы Σ .
- $\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_d)$ — диагональная матрица собственных значений, упорядоченных по невозрастанию: $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d \geq 0$.

Сделаем замену переменных, перейдя в базис из собственных векторов. Пусть:

$$u = Q^T v \quad (6)$$

Поскольку преобразование задается ортогональной матрицей Q , длина вектора при данном отображении сохраняется (изометрия):

$$\|u\|^2 = u^T u = (Q^T v)^T (Q^T v) = v^T Q Q^T v = v^T I v = v^T v = 1 \quad (7)$$

Подставим спектральное разложение матрицы Σ в выражение для максимизируемой дисперсии:

$$v^T \Sigma v = v^T (Q \Lambda Q^T) v = (v^T Q) \Lambda (Q^T v) = u^T \Lambda u \quad (8)$$

Распишем полученное произведение в координатной форме, учитывая диагональный вид матрицы Λ :

$$u^T \Lambda u = \sum_{i=1}^d \lambda_i u_i^2 \quad (9)$$

5. Поиск максимума дисперсии

Теперь задача сводится к максимизации линейной комбинации $\sum_{i=1}^d \lambda_i u_i^2$ при условиях:

$$\sum_{i=1}^d u_i^2 = 1 \quad \text{и} \quad u_i^2 \geq 0 \quad (10)$$

Так как λ_1 — наибольшее собственное значение ($\lambda_1 \geq \lambda_i$ для всех $i = 1, \dots, d$), справедливо следующее неравенство:

$$\sum_{i=1}^d \lambda_i u_i^2 \leq \sum_{i=1}^d \lambda_1 u_i^2 = \lambda_1 \sum_{i=1}^d u_i^2 = \lambda_1 \cdot 1 = \lambda_1 \quad (11)$$

Таким образом, верхняя граница для дисперсии спроецированных данных ограничена максимальным собственным значением матрицы ковариаций: $\text{Var}(Xv) \leq \lambda_1$.

6. Определение оптимального направления

Выясним, при каком векторе v достигается этот максимум. Равенство $\sum_{i=1}^d \lambda_i u_i^2 = \lambda_1$ при условии $\sum_{i=1}^d u_i^2 = 1$ (в предположении для простоты, что $\lambda_1 > \lambda_2$) достигается тогда и только тогда, когда вся «весовая масса» сосредоточена на первой координате нового базиса:

$$u = \begin{pmatrix} 1 \\ 0 \\ \dots \\ 0 \end{pmatrix} \quad (12)$$

Для возвращения к исходной системе координат выполним обратное преобразование $v = Qu$:

$$v = Qu = [e_1, e_2, \dots, e_d] \begin{pmatrix} 1 \\ 0 \\ \dots \\ 0 \end{pmatrix} = 1 \cdot e_1 + 0 \cdot e_2 + \dots + 0 \cdot e_d = e_1 \quad (13)$$

Вывод

Оптимальное направление v , максимизирующее дисперсию спроецированных данных, строго совпадает с вектором e_1 — собственным вектором матрицы ковариаций Σ , отвечающим её максимальному собственному значению λ_1 .

Для поиска последующих главных компонент задача максимизации дисперсии решается аналогично в ортогональном дополнении к подпространству $\text{span}(e_1)$, что последовательно приводит к собственным векторам e_2, e_3 и т. д., соответствующим упорядоченным по убыванию собственным значениям.